



| **UNR** Universidad
Nacional de Rosario

LICENCIATURA EN ESTADÍSTICA

METRÓPOLIS-HASTINGS

“Markov chain Monte Carlo (MCMC) method”

Autores: Franco Santini - Nicolas Gamboa - Andrés Roncaglia

Docentes: Ignacio Evangelista - Tomás Capretto

2024

Tabla de contenidos

Introducción	1
Metodología	1
Discusiones	6
Metropolis-Hastings en una dimensión	6
Distribución de Kumaraswamy	6
Metropolis-Hastings en dos dimensiones	10
Normal Bivariada	10
Función de Rosenbrock	16
Conclusión	21
Anexo	22

Introducción

Uno de los grandes problemas en el mundo de la estadística es la existencia de distribuciones cuyas funciones de densidad son tan complejas que resultan difíciles de trabajar. Es por esto que muchas veces resulta de utilidad trabajar con muestras aleatorias, y a partir de estas responder determinadas preguntas. En la práctica, es común encontrarse con variables aleatorias con funciones de densidad cuyo muestreo directo no es simple.

Para estos casos existen distintas técnicas que permiten obtener muestras que, si bien no son tomadas de manera realmente independiente, se comportan de manera muy similar a como lo haría una muestra aleatoria independiente tomada de la función de densidad.

Particularmente en el campo de la *Estadística Bayesiana*, esto resulta útil ya que permite obtener muestras de la distribución a posteriori, la cual se puede utilizar por ejemplo para obtener un intervalo de credibilidad del parámetro bajo estudio.

Un método sencillo de emplear y que reporta buenos resultados es el algoritmo de *Metropolis-Hastings*.

Metodología

Si se quiere obtener una muestra de la función de densidad $f(x)$, de la cual no es sencillo obtener muestras, el algoritmo de Metropolis-Hastings plantea que proponiendo una función $q(x)$ conocida, de la cual es sencillo muestrear, y un punto inicial (θ_0) es posible obtener muestras de la función $f(x)$.

El método funciona de la siguiente forma:

- De la distribución $q(x)$ centrada en θ_0 muestrear un nuevo punto (θ')
- Si la densidad de la función $f(x)$ es mayor en θ' que en θ_0 , entonces θ' formará parte de la muestra, en caso contrario será parte de la muestra con probabilidad $\frac{f(\theta')}{f(\theta_0)} \frac{q(\theta_0)}{q(\theta')}$ o con probabilidad $1 - \frac{f(\theta')}{f(\theta_0)} \frac{q(\theta_0)}{q(\theta')}$ se repetirá θ en la muestra.
- Repetir el proceso, obteniendo nuevos puntos propuestos a partir de $q(x)$ centrada en el último valor muestreado.

En definitiva, la probabilidad de seleccionar θ' como nuevo valor de la muestra es $\alpha = \min \left\{ 1; \frac{f(\theta')}{f(\theta_0)} \frac{q(\theta_0)}{q(\theta')} \right\}$




Figura 1: Ejemplificación de la obtención de una muestra por el método de Metropolis-Hastings

A continuación se presentan las funciones usadas para aplicar el método en los casos en los que f es unidimensional y bidimensional:

i Algoritmo Metrópolis-Hastings univariado

```
sample_mh <- function(n, d_objetivo, r_propuesta = NULL,
                      d_propuesta = NULL, p_inicial = NULL){

  # Posibles errores al llamar a la función
  if (length(p_inicial) != 1) {
    stop("El valor p_inicial debe ser unidimensional")
  }
  if ( n <= 0 || n %% 1 != 0 ) {
    stop("El tamaño de muestra n debe ser entero y mayor que 0")
  }

  # En caso de no definir una distribución propuesta se utiliza
  # una normal con varianza igual a 1
  if (is.null(r_propuesta) | is.null(d_propuesta)) {
    r_propuesta <- function(media) rnorm(n = 1, media, sd = 1)
    d_propuesta <- function(x, media) dnorm(x = x, media, sd = 1)
  }
}
```

i

```
# Se definen valores iniciales
stopifnot(n > 0)
contador <- 0
muestras <- numeric(n)
muestras[1] <- p_inicial

# Iteraciones para obtener las n-1 muestras restantes
for(i in 2:n) {
  # Se define el valor actual, y el nuevo valor propuesto
  p_actual <- muestras[i-1]
  p_propuesta <- r_propuesta(p_actual)

  # Se calculan las densidades de estos
  # valores para las distribuciones propuesta y objetivo
  q_actual <- d_propuesta(p_actual, p_propuesta)
  q_nuevo <- d_propuesta(p_propuesta, p_actual)
  f_actual <- d_objetivo(p_actual)
  f_nuevo <- d_objetivo(p_propuesta)

  # Si la densidad del valor actual para la distribución obj es 0,
  # se elige el nuevo valor propuesto con probabilidad 1

  if (f_actual == 0 || q_nuevo == 0) {
    alfa <- 1
  } else {
    alfa <- min(1, (f_nuevo/f_actual)*(q_actual/q_nuevo))
  }

  # Se elige el nuevo valor de la muestra con una probabilidad alfa
  muestras[i] <- sample(c(p_propuesta, p_actual),
                        size = 1, prob = c(alfa, 1-alfa))

  # Se actualiza el número de saltos aceptados
  if(muestras[i] != muestras[i-1]) {
    contador <- contador + 1
  }
}

# Devuelve una lista con 2 elementos. Un data frame con la
# muestra y la tasa de aceptación.
return(list(cadena = data.frame(iteracion = 1:n, x = muestras),
           tasa_aceptacion = contador / n))
}
```

i Algoritmo Metrópolis-Hastings bivariado

```
sample_mh_mv <- function(n, d_objetivo, cov_propuesta = diag(2),
                          p_inicial = numeric(2)) {

  # Posibles errores al llamar a la función
  if (length(p_inicial) != 2) {
    stop("El valor p_inicial debe ser bidimensional")
  }
  if (n <= 0 || n %% 1 != 0) {
    stop("El tamaño de muestra n debe ser entero y mayor que 0")
  }
  if (any((dim(cov_propuesta) != c(2,2)))) {
    stop("La matriz de covariancia debe ser de 2x2")
  }

  # Distribuciones propuestas a utilizar
  r_propuesta <- function(media) rmvnorm(n = 1, mean = media, sigma = cov_propuesta)
  d_propuesta <- function(x, media) dmnorm(x = x, mean = media, sigma = cov_propuesta)

  # Se definen valores iniciales
  contador <- 0
  muestras <- matrix(0, nrow = n, ncol = length(p_inicial))
  muestras[1, ] <- p_inicial

  # Iteraciones para obtener las n-1 muestras restantes
  for(i in 2:n) {
    # Se define el valor actual, y el nuevo valor propuesto
    p_actual <- muestras[i-1,]
    p_propuesta <- r_propuesta(p_actual)

    # Se calculan las densidades de estos
    # valores para las distribuciones propuesta y objetivo
    q_actual <- d_propuesta(p_actual, p_propuesta)
    q_nuevo <- d_propuesta(p_propuesta, p_actual)
    f_actual <- d_objetivo(p_actual)
    f_nuevo <- d_objetivo(p_propuesta)
```

i

```
# Si la densidad del valor actual para la distribución obj es 0,
# se elige el nuevo valor propuesto con probabilidad 1
if (f_actual == 0 || q_nuevo == 0) {
  alfa <- 1
} else {
  alfa <- min(1, (f_nuevo/f_actual)*(q_actual/q_nuevo))
}

# Se elige el nuevo valor de la muestra con una probabilidad alfa
aceptar <- rbinom(1,1,alfa)
if (aceptar) {
  muestras[i,] <- p_propuesta
}else{
  muestras[i,] <- p_actual
}

# Se actualiza el número de saltos aceptados
if(!any(muestras[i,] != muestras[i-1,])) {
  contador <- contador + 1
}
}

salida <- data.frame(iteracion = 1:n, x = muestras) |>
  `colnames<-`(c("iteracion", paste0("dim_",1:length(p_inicial))))

# Devuelve una lista con 2 elementos. Un data frame con la
# muestra y la tasa de aceptación.
return(list(muestra_mh = salida,
  probabilidad_aceptacion = contador / n))
}
```

Discusiones

Metropolis-Hastings en una dimensión

Distribución de Kumaraswamy

La distribución de Kumaraswamy es una distribución de probabilidad continua que se utiliza para modelar variables aleatorias con soporte en el intervalo $(0, 1)$, cuya función de densidad es:

$$f(x|a, b) = abx^{a-1}(1-x)^{b-1}, \text{ con } a, b > 0$$




Figura 2: Función de densidad de la distribución de Kumaraswamy

Esta distribución puede ser utilizada en el ámbito de la estadística bayesiana a la hora de definir un prior para un parámetro con campo de variación en el intervalo $(0, 1)$.

Por lo general la distribución elegida para estas situaciones suele ser la beta ya que presenta ventajas como ser una distribución conjugada de la binomial, lo cual puede facilitar mucho algunos cálculos. El problema es que la densidad de esta depende de la función gamma, la cual es una integral, y en algunas situaciones se puede complicar su cálculo.

La distribución de Kumaraswamy se comporta de manera muy similar a la beta, sin tener el problema de la dificultad del cálculo de la integral.

A continuación utilizaremos el algoritmo de Metropolis-Hastings para generar 5000 muestras de la distribución de *Kumaraswamy* con parámetros $a = 6$ y $b = 2$, utilizando como distribución propuesta una $Beta(\mu, \kappa)$, donde μ representa la media de la distribución y κ el grado de la concentración de la distribución. Esto lo haremos para 3 valores distintos de κ .

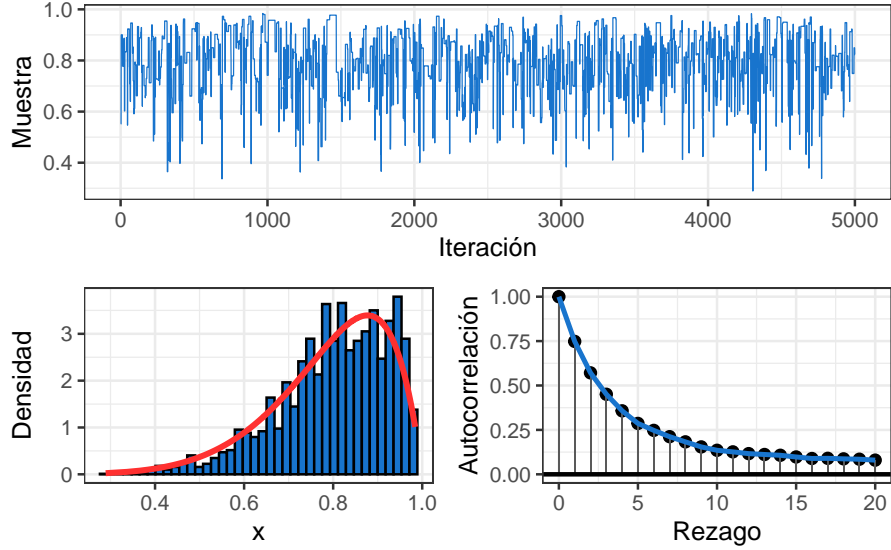


Figura 3: Muestreo por Metropolis-Hastings con $\kappa = 1$

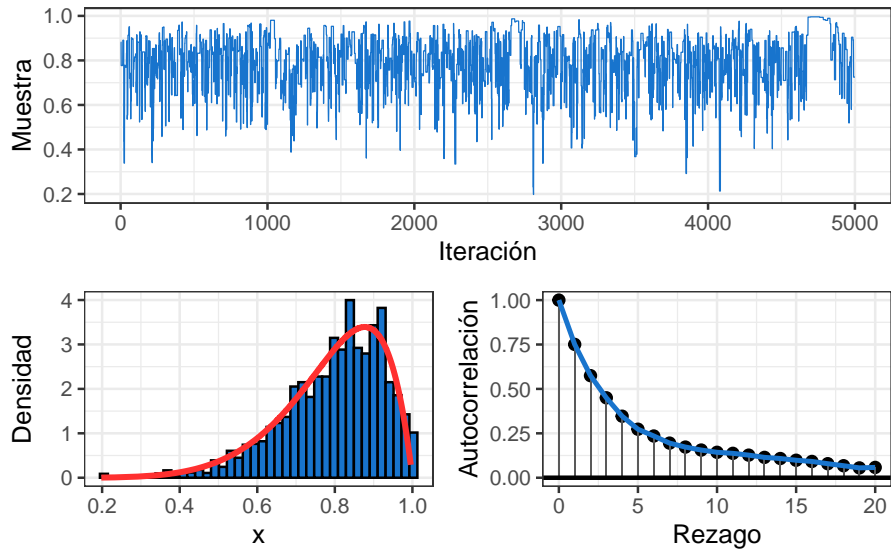


Figura 4: Muestreo por Metropolis-Hastings con $\kappa = 2$

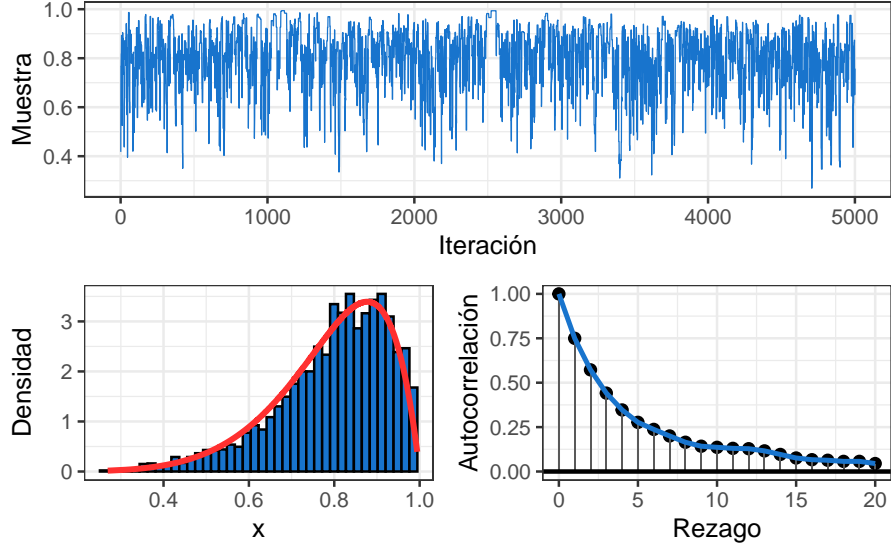


Figura 5: Muestreo por Metropolis-Hastings con $\kappa = 5$

Teniendo en cuenta que estas muestras son dependientes resulta de interés conocer a cuantas muestras independientes equivalen, dado que cuanto más se comporta una cadena de Markov dependiente como una muestra independiente, menor es el error en la aproximación posterior resultante. Para ello se calcula el número efectivo de muestras (n_{eff}) para cada cadena.

Tabla 1: Número efectivo de muestras para cadenas de 5000 muestras y distintos valores de κ

Cadena	κ	n_{eff}
Cadena 1	1	485
Cadena 2	2	358
Cadena 3	5	503

Con esto concluimos que el valor de κ que arroja una muestra relacionada que equivale a una independiente de mayor tamaño es 5. Sin embargo esta cantidad de muestras independientes es muy pobre teniendo en cuenta que el tamaño de la cadena es de 5000 muestras.

Resulta de interés ver como afecta la elección del parámetro κ al utilizar Metropolis-Hastings para obtener muestras de la distribución de Kumaraswamy usando una distribución *Beta* como propuesta. Es por esto que se decide obtener la media y ciertos cuantiles sobre las muestras obtenidas y sobre la función Logit de estas.

Tabla 2: Media y cuantiles estimadas para las funciones X y $Logit(X)$

$f(x)$	κ	$E(\hat{x})$	$q_{0.05}$	$q_{0.95}$
X	1	0.802	0.571	0.959
	2	0.797	0.545	0.971
	5	0.799	0.534	0.969
$Logit(X)$	1	1.615	0.287	3.165
	2	1.636	0.182	3.528
	5	1.632	0.137	3.432

Las estadísticas reales de la distribución de Kumaraswamy son:

Tabla 3: Media y cuantiles para las funciones X y $Logit(X)$

$f(x)$	$E(x)$	$q_{0.05}$	$q_{0.95}$
X	0.791	0.542	0.959
$Logit(X)$	1.547	0.168	3.145

Si bien las diferencias en dispersión de las muestras no son muy perceptibles a simple vista, gracias a la función logit podemos percibir las con mayor facilidad. Es así que se puede concluir que usando una distribución *Beta* con un parámetro $\kappa = 2$ de concentración, es que se obtienen las estimaciones más cercanas a la distribución de Kumaraswamy con parámetros $a = 6$ y $b = 2$.

Metropolis-Hastings en dos dimensiones

Normal Bivariada

El algoritmo de Metropolis-Hastings se aprecia más cuando se obtienen muestras de distribuciones en más de una dimensión, incluso cuando no se conoce la constante de normalización, sin embargo tiene limitaciones para ciertas funciones, las cuales se verán a continuación.

Para testear el algoritmo de Metropolis-Hastings bivariado creado, se decide obtener muestras de una distribución Normal bivariada con vector de media μ^* y matriz de covarianza Σ^* con el algoritmo ya mencionado.

Donde $\mu^* = \begin{bmatrix} 0.4 \\ 0.75 \end{bmatrix}$ y $\Sigma^* = \begin{bmatrix} 1.35 & 0.4 \\ 0.4 & 2.4 \end{bmatrix}$.

Se plantean 3 matrices de covarianzas distintas como propuestas para observar con cual de estas se obtienen muestras mas aproximadas a la verdadera distribución:

1. $\Sigma_1 = \begin{bmatrix} 1 & 0 \\ 0 & 2 \end{bmatrix}$ Se puede ver su densidad en la Figura 6, el recorrido de la cadena en la Figura 7 y su autocorrelación en la Figura 8.
2. $\Sigma_2 = \begin{bmatrix} 0.25 & 0 \\ 0 & 0.25 \end{bmatrix}$ Se puede ver su densidad en la Figura 9, el recorrido de la cadena en la Figura 10 y su autocorrelación en la Figura 11.
3. $\Sigma_3 = \begin{bmatrix} 1 & 0.3 \\ 0.3 & 1 \end{bmatrix}$ Se puede ver su densidad en la Figura 12, el recorrido de la cadena en la Figura 13 y su autocorrelación en la Figura 14.




Figura 6: Distribución de las muestras obtenidas por Metropolis-Hastings de una $\mathcal{N}_2(\mu^*, \Sigma^*)$ con Σ_1 como propuesta




Figura 7: Cadena de Markov de las muestras obtenidas por Metropolis-Hastings de una $\mathcal{N}_2(\mu^*, \Sigma^*)$ con Σ_1 como propuesta




Figura 8: Autocorrelación de las muestras obtenidas por Metropolis-Hastings de una $\mathcal{N}_2(\mu^*, \Sigma^*)$ con Σ_1 como propuesta




Figura 9: Distribución de las muestras obtenidas por Metropolis-Hastings de una $\mathcal{N}_2(\mu^*, \Sigma^*)$ con Σ_2 como propuesta




Figura 10: Cadena de Markov de las muestras obtenidas por Metropolis-Hastings de una $\mathcal{N}_2(\mu^*, \Sigma^*)$ con Σ_2 como propuesta




Figura 11: Autocorrelación de las muestras obtenidas por Metropolis-Hastings de una $\mathcal{N}_2(\mu^*, \Sigma^*)$ con Σ_2 como propuesta




Figura 12: Distribución de las muestras obtenidas por Metropolis-Hastings de una $\mathcal{N}_2(\mu^*, \Sigma^*)$ con Σ_3 como propuesta




Figura 13: Cadena de Markov de las muestras obtenidas por Metropolis-Hastings de una $\mathcal{N}_2(\mu^*, \Sigma^*)$ con Σ_3 como propuesta




Figura 14: Autocorrelación de las muestras obtenidas por Metropolis-Hastings de una $\mathcal{N}_2(\mu^*, \Sigma^*)$ con Σ_3 como propuesta

Tabla 4: Número efectivo de muestras para cadenas de 5000 muestras y distintos valores de Σ

Cadena	x_1	x_2
Cadena 1	340	377
Cadena 2	171	85
Cadena 3	523	235

Considerando los tamaños de muestras efectivos en cada dimensión y los gráficos de autocorrelación observados, se puede concluir que con la matriz de covarianzas Σ_1 se obtienen muestras aparentemente mejores de la distribución objetivo.

Para ver la bondad de la muestra generada por Metropolis-Hastings, se calculan ciertas probabilidades y luego se comparan con otros métodos de cálculo de probabilidades, como “Función de distribución” y “Método de MonteCarlo”.

Tabla 5: Cálculo de probabilidades con distintos métodos

Método	$P(X_1 > 1, X_2 < 0)$	$P(X_1 > 1, X_2 > 2)$	$P(X_1 > 0.4, X_2 > 0.75)$
M-H	0.0858	0.0654	0.2332
Función de distribución	0.0683	0.0870	0.2857
MC	0.0754	0.0910	0.2808

Podemos concluir que las estimaciones de las probabilidades calculadas son bastante acertadas, debido a su similitud con los otros métodos.

Función de Rosenbrock

Es una función matemática, popularmente conocida como *La banana de Rosenbrock* utilizada frecuentemente como prueba de algoritmos de optimización numérica.

$$f(x, y) = (a - x)^2 + b(y - x^2)^2$$

En el campo de la Estadística Bayesiana, es muy conocida dado que la densidad del posterior muchas veces toma una forma que se asemeja a la función de *Rosenbrock*.

Un ejemplo de este fenómeno es la función de densidad que viene dada por:

$$p^*(x_1, x_2 | a, b) = \exp\{ -[(a - x_1)^2 + b(x_2 - x_1^2)^2] \}, \quad a, b \in \mathbb{R}$$

Para poner a prueba el algoritmo de Metropolis-Hastings bivariado en situaciones complejas, se decide obtener 5000 muestras de la función anteriormente mencionada, con parámetros $a = 0.5$ y $b = 5$. Se utilizan 3 distintas matrices de covarianzas propuestas, las cuáles son:

1. $\Sigma_1 = \begin{bmatrix} 0.06 & 0 \\ 0 & 0.07 \end{bmatrix}$ Se puede ver su densidad en la Figura 15, el recorrido de la cadena en la Figura 16 y la autocorrelación en la Figura 17. Con esta matriz la probabilidad de aceptación es 0.411.
2. $\Sigma_2 = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$ Se puede ver su densidad en la Figura 18, el recorrido de la cadena en la Figura 19 y la autocorrelación en la Figura 20. Con esta matriz la probabilidad de aceptación es 0.8092.
3. $\Sigma_3 = \begin{bmatrix} 0.5 & 0 \\ 0 & 0.5 \end{bmatrix}$ Se puede ver su densidad en la Figura 21, el recorrido de la cadena en la Figura 22 y la autocorrelación en la Figura 23. Con esta matriz la probabilidad de aceptación es 0.7114.




Figura 15: Distribución de las muestras obtenidas por Metropolis-Hastings de p^* con Σ_1 como propuesta




Figura 16: Cadena de Markov de las muestras obtenidas por Metropolis-Hastings de p^* con Σ_1 como propuesta




Figura 17: Autocorrelación de las muestras obtenidas por Metropolis-Hastings de p^* con Σ_1 como propuesta




Figura 18: Distribución de las muestras obtenidas por Metropolis-Hastings de p^* con Σ_2 como propuesta




Figura 19: Cadena de Markov de las muestras obtenidas por Metropolis-Hastings de p^* con Σ_2 como propuesta




Figura 20: Autocorrelación de las muestras obtenidas por Metropolis-Hastings de p^* con Σ_1 como propuesta




Figura 21: Distribución de las muestras obtenidas por Metropolis-Hastings de p^* con Σ_3 como propuesta




Figura 22: Cadena de Markov de las muestras obtenidas por Metropolis-Hastings de p^* con Σ_3 como propuesta




Figura 23: Autocorrelación de las muestras obtenidas por Metropolis-Hastings de p^* con Σ_1 como propuesta

Tabla 6: Número efectivo de muestras para cadenas de 5000 muestras y distintos valores de Σ

Cadena	x_1	x_2
Cadena 1	30	46
Cadena 2	149	94
Cadena 3	67	43

Considerando en los tamaños de las muestras efectivas en cada dimensión y en los gráficos de autocorrelación observados, parece que la matriz de covarianzas Σ_2 genera muestras que ajustan mejor a la distribución objetivo.

Para ver que tan bien funciona Metropolis-Hastings en esta situación compleja, interesa calcular ciertas probabilidades y compararlas con el método de “Integración Manual”.

Tabla 7: Cálculo de probabilidades con distintos métodos

Método	$P(A, B)^1$	$P(C, D)^2$	$P(E, F)^3$
M-H	0.3954	0.1602	0.0588
Integración numérica	0.5137	0.2022	0.0838

¹ $A = 0 < X_1 < 1, B = 0 < X_2 < 1$

² $C = -1 < X_1 < 0, D = 0 < X_2 < 1$

³ $E = 1 < X_1 < 2, F = 2 < X_2 < 3$

Se puede observar que el algoritmo en esta situación falla bastante en la generación de las muestras, dado que la estimación de las probabilidades son muy diferentes a las calculadas por un método casi exacto.

Conclusión

Metropolis-Hastings es una herramienta muy útil y sencilla de emplear para generar muestras de distribuciones cuya complejidad se escapa de los métodos de muestreo más populares y directos. A lo largo del estudio se lograron detectar múltiples características tanto positivas como negativas de este método tan utilizado en el campo de la estadística bayesiana.

Este método brinda buenos resultados cuando la distribución a muestrear es unidimensional, o en el caso bidimensional siempre y cuando la distribución tenga una forma “sencilla”, como por ejemplo una normal bivariada.

Una limitación que presenta es el costo computacional en casos de alta dimensionalidad, o cuando la forma de la distribución a muestrear es muy atípica o con grandes picos como por ejemplo en el caso de la *banana de Rosenbrock*.

Anexo

Se pueden replicar los resultados y comprobar los códigos utilizados consultando el [repositorio](#) del trabajo.